文章编号：1000-3673（2020）09-3488-09　　中图分类号：TM 73　　文献标志码：A　　学科代码：470·40

电力用户用电特征选择与行为画像

赵晋泉[1]，夏雪[1]，刘子文[1]，徐春雷[2]，苏大威[2]，闪鑫[3]

（1. 河海大学 能源与电气学院，江苏省 南京市 210098；
2. 国网江苏省电力有限公司，江苏省 南京市 210024；
3. 南瑞集团公司(国网电力科学研究院)，江苏省 南京市 211106）

User Electricity Consumption Feature Selection and Behavioral Portrait

ZHAO Jinquan[1], XIA Xue[1], LIU Ziwen[1], XU Chunlei[2], SU Dawei[2], SHAN Xin[3]

(1. College of Energy and Electrical Engineering, Hohai University, Nanjing 210098, Jiangsu Province, China;
2. State Grid Jiangsu Electric Power Co., Ltd., Nanjing 210024, Jiangsu Province, China;
3. NARI Group Corporation (State Grid Electric Power Research Institute), Nanjing 211106, Jiangsu Province, China)

ABSTRACT: The stable operation of China's AC/DC bulk power grid and the accommodation of renewable energy put forward high requirements on the demand response. User portrait is of great significance to the implementation of the demand response. Therefore, a method of user electricity consumption feature selection and behavioral portrait is proposed in this paper. Firstly, the clustering return index is constructed, in which taking into account the degree of aggregation and separation, the optimal cluster number is obtained automatically and k-means clustering is completed. Then, the maximal relevance and minimal redundancy (mRMR) criterion is applied to the selection of user electricity consumption features, in which the high-quality feature set is obtained by using enumeration method. Finally, the high-quality features are quantified by the scoring method, and a radar map and a histogram are used to show the users electricity consumption behavior portrait. The results of an example show that the proposed method is effective.

KEY WORDS: electricity consumption behavior portrait; feature selection; maximal relevance and minimal redundancy criterion; clustering return index; clustering

摘要: 我国交直流大电网的安全稳定运行与新能源的消纳对需求侧响应提出了较高要求，电力用户画像对需求侧响应的实施具有重要意义。文章提出了一种电力用户用电特征选择与行为画像方法。首先，通过构造聚合回报指标，兼顾集聚度和分离度，实现了最优分类数目的自动确定，并在此基础上完成 k-means 聚类；然后，将最大相关最小冗余准则应用于电力用户用电特征选取，兼顾了有效性和精简性，通过遍历法求得优质特征集；再采用打分制对优质特征进行量化，通过雷达图和柱状图等进行展示，实现了用户用电行为画像。最后通过算例分析表明了所提方法的有效性。

关键词: 用电行为画像；特征选择；最大相关最小冗余准则；聚合回报指标；聚类分析

DOI：10.13335/j.1000-3673.pst.2019.2138

0　引言

我国交直流大电网的安全稳定运行与大规模风光等新能源的消纳对受端电网需求侧响应提出了高要求，电力用户画像对需求侧响应的实施与制订具有重要意义[1]。智能量测终端的大量投用，使得用户数据得以实时采集，这些数据的相似性与关联性反映了用户用电习惯与行为特性[2]。利用这些数据构建用电特征可为需求侧响应提供决策依据。用户画像作为真实用户的虚拟代表，是建立在一系列真实数据之上的用户模型[3]。由数据组成的“用户画像”可以再现用户的全貌，是企业挖掘用户需求与价值、进行用户细分、实施精准营销的基础。

近年来电力用户画像研究逐渐兴起，研究可分为两类。一类是架构型研究[4-5]。这类文献构建了用户画像的不同技术框架，并对其中关键实现技术与具体应用做了介绍。另一类是对用户画像分类模型的研究[6-7]。文献[6]采用模糊聚类算法进行客户用电模式分析，实现不同类型用户的用电行为模式画像。文献[7]利用密度聚类算法将不同电力用户划分成不同属性的簇，并为不同用户簇建立标签化的用户画像模型。这类研究多着眼于用户的分类，但其特征选取都是依赖于专家经验，可靠性较低。而用户用电特征的选取是电力用户画像的本质，因此选

基金项目：国家重点研发计划项目(2017YFB0902600)；国家电网有限公司科技项目(SGJS0000DKJS1700840)。

Project Supported by National Key R & D Program of China (2017YFB0902600); Science and Technology Foundation of SGCC (SGJS0000DKJS1700840).

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

取满足精简性要求的同时最大化反映用户用电行为特性的特征是绘制精准可靠的用户画像的重要基础。文献[8]为提高特征选取的可靠性，基于客观指标构建特征评价函数，以互信息量与相关系数作为特征有效性和关联性指标，为特征量的选取提供了可靠依据。但文中只将互信息与相关系数进行简单叠加作为评价函数，不能全面均衡地反映所选特征集的有效性与精简性。

文献[9]提出了一种最大相关最小冗余准则(maximal relevance and minimal redundancy，mRMR)，可用于从特定特征集寻找满足与目标类别相关性最大、相互间冗余性最小的特征子集。目前，该准则已经被应用到变压器故障诊断[10]、暂态稳定判别[11]和风电功率预测[12-13]等的特征选取中。以该准则为判据可以综合计及特征的有效性与冗余性，从而选取出与用户类别联系最为密切且最精简的标签集。因此，本文将该准则应用到用户用电特征选取中。

本文提出了一种电力用户用电特征选择与行为画像方法。首先，通过构造兼顾集聚度和分离度的聚合回报指标以自动确定最优分类数，并基于此完成 k-means 聚类；然后，将 mRMR 用于用户用电特征集的构建，更全面均衡地反映所选特征集的有效性与精简性，采用遍历法求解 mRMR，得到满足判据的最优特征集；最后，将选取的特征进行量化并形成用户用电行为画像标签，通过雷达图和柱状图等实现可视化，直观展示用户用电特性。通过算例分析表明了本文方法的有效性。

1　聚类分析

电力用户用电行为画像的第一步是对用电数据样本进行聚类分析。本文采用 k-means 聚类算法，该算法是一种无监督学习算法，可以实现大型数据集的快速高效分类[14]。但 k-means 算法存在类别数 k 难确定的问题，目前，常用解决方法可大致分为以下几种：通过 canopy 算法过渡的方法[15]；基于密度构建决策图的方法[16]；二分迭代寻优方法[17]；基于云模型理论的方法[18]和通过聚类有效性指标控制的方法[19-20]。其中，采用聚类有效性指标控制 k 值选取的方法是通过建立聚类有效性指标，评价聚类质量并确定最佳聚类数[21]，思想简单，受样本分布的影响不大，且不需要人为设定阈值。因此本文采用该类方法确定 k 值。本文以误差平方和(sum of squared error，SSE)为基础，得到误差降低系数指标，并将其与轮廓系数相结合，构建了聚合回报指标，综合计及聚类的集聚度和分离度，实现类别数 k 的自动确定。

首先，误差平方和(sum of squared error，SSE)的定义[22]如下：

$$I_{\mathrm{SSE}}(k)=\sum_{i=1}^{k}\sum_{x\in C_i}|x-m_i|^2 \tag{1}$$

式中：I_{SSE} 为误差平方和；C_i 为第 i 个类别；x 为 C_i 中的样本点；m_i 为 C_i 的质心，即所有样本的均值。

当 k 值小于最佳聚类数时，k 值的增加会大幅增加每个簇的集聚程度，故 SSE 值的下降幅度会陡增，而当 k 值达到最佳聚类数时，再增加 k 值所得到的集聚程度回报会迅速变小，SSE 值下降幅度会骤减。为量化集聚程度回报大小，定义误差降低系数 β_{SSE} 为

$$\beta_{\mathrm{SSE}}=\frac{I_{\mathrm{SSE}}(k-1)-I_{\mathrm{SSE}}(k)}{I_{\mathrm{SSE}}(k)-I_{\mathrm{SSE}}(k+1)} \tag{2}$$

针对样本点 x_i，假设其被聚类到簇 A，则其轮廓系数[19]如下：

$$I_{\mathrm{SC}}(x_i)=\frac{b(x_i)-a(x_i)}{\max(a(x_i),b(x_i))} \tag{3}$$

式中：I_{SC} 为轮廓系数；$a(x_i)$ 为样本 x_i 到簇 A 其他样本点的平均欧式距离；对于簇 B 而言，令 $D(x_i,B)$ 为样本 x_i 与簇 B 中所有样本的平均欧氏距离，则 $b(x_i)=\min_{B\neq A}\{D(x_i,B)\}$，即为样本 x_i 到其他簇的平均距离的最小值。

求出所有样本的轮廓系数后取平均值即可得到样本集的平均轮廓系数：

$$I_{\overline{\mathrm{SC}}}=\frac{1}{n}\sum_{x_i\in C}I_{\mathrm{SC}}(x_i) \tag{4}$$

式中：$I_{\overline{\mathrm{SC}}}$ 为平均轮廓系数；C 为总样本集；n 为总样本数。

误差降低系数反映的是簇内集聚度，平均轮廓系数则体现了簇间分离度。因此，综合两个系数定义了聚合回报指标 I_{Re}：

$$I_{\mathrm{Re}}=\beta_{\mathrm{SSE}}+I_{\overline{\mathrm{SC}}} \tag{5}$$

给定一个最大聚类数 $k_{\max}$，取2 $k_{\max}$ 的范围内每个整数作为聚类数，分别进行一次聚类。当聚合回报值最大时，聚类结果最优。这样通过定义聚合回报指标，实现了最佳聚类数 k 值的自动确定。

确定最佳 k 值后，采用 k-means 算法对样本进行聚类分析，得到各用户的类别标签。

2　基于 mRMR 的特征选取

2.1　初始特征集的确定

在电力用电行为分析中，通常会采用源于用电

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

曲线的用电特征来表征用户用电行为。常用的用电特征可分为两大类，一类是直观描述型，包括日用电量[14,23]、日最大负荷[14,23]、日最小负荷[14,23]、日平均负荷[23]、日峰谷差[23]等；另一类是比值描述型，包括谷电系数[24-25]、日负荷率[24-25]、日峰谷差率[23]、峰时耗电率[24-25]、平时段用电百分比[24-25]等。原始特征集可由上述两类特征组合构成。可记为 $T=\{t_1,t_2,\cdots,t_N\}$。

2.2 最大相关最小冗余准则

最大相关最小冗余准则是一种滤波式特征选择方法[9]。其核心思想为最大化特征与分类变量之间的相关性，最小化特征与特征之间的冗余性。本文将其应用于用户用电特征选取中，得到相关性最强、冗余度最低的特征集，用以表征用户用电特性。

特征与分类变量相关性以特征与分类变量之间的互信息值作为衡量指标，其表征的是已知该特征时类别不确定性减少程度。在求解过程中，为了让各特征变量更具有统计学意义，需要对各个变量进行变量域离散化处理，即把各个变量的数值序列转化为概率分布区间[12,26]。本文先对特征进行归一化处理，再将变量区间均匀离散，得到各特征变量的概率分布，继而完成对各个特征量与用户类别的互信息计算。

在信息论中，熵作为信息不确定性的一个测度，熵越大表示信息不确定的程度越高。X 的熵的计算公式[8]为

$$H(X)=-\sum_{x\in U}p(x)\log_2 p(x) \tag{6}$$

式中：U 为 X 所有可能事件集合；$p(x)$ 为具体事件 x 发生的概率。

经离散化处理后，可得到第 i 个特征 t_i 的熵的计算公式为

$$H(t_i)=-\sum_{u=1}^{N_i}\left[\frac{M_u}{M}\log_2\frac{M_u}{M}\right] \tag{7}$$

式中：N_i 为特征 t_i 的区间数量；M_u 为特征 t_i 落在第 u 个区间的样本个数；M 为总样本数。

用户类别 d 的信息熵为

$$H(d)=-\sum_{v=1}^{N_d}\left[\frac{M_v}{M}\log_2\frac{M_v}{M}\right] \tag{8}$$

式中：N_d 为用户总类别数；M_v 为属于第 v 个类别的样本个数。

第 i 个特征 t_i 与用户类别 d 的联合信息熵为

$$H(t_i,d)=-\sum_{u=1}^{N_i}\sum_{v=1}^{N_d}\left[\frac{M_{uv}}{M}\log_2\frac{M_{uv}}{M}\right] \tag{9}$$

式中：M_{uv} 为 t_i 落在第 u 个区间且用户类别为 v 的样本个数。

第 i 个特征 t_i 与用户类别 d 的互信息定义为

$$I(t_i;d)=H(t_i)+H(d)-H(t_i,d) \tag{10}$$

根据式(10)即可分别求出每个特征与用户类别间的互信息。

最优特征集与类别 d 最大相关性指标 $D(S,d)$[9]为

$$D(S,d)=\frac{1}{N_S}\sum_{i=1}^{N_S}I(t_i;d) \tag{11}$$

式中：S 与 N_S 为最优特征集及其所包含特征的个数；t_i 为 S 中的第 i 个特征；$I(t_i;d)$ 为 S 中第 i 个特征和用户类别 d 之间的互信息值。

两个特征间信息的冗余性可以用信息增益、基尼系数、相关系数等指标来衡量。本文采用相关系数，其公式[8]如下：

$$\rho_{t_it_j}=\frac{\mathrm{cov}(t_i,t_j)}{\rho_{t_i}\rho_{t_j}} \tag{12}$$

式中：t_i 和 t_j 分别为最优特征集 S 中第 i 和第 j 个特征；$\mathrm{cov}(t_i,t_j)$ 为两个特征的协方差；ρ_{t_i} 和 ρ_{t_j} 分别为特征 t_i 和 t_j 的标准差；$\rho_{t_it_j}$ 为两个特征的相关系数，取值范围为[–1, 1]，绝对值越接近于 1，相关性越大，越接近 0，相关性越小。

最小冗余性指标 $R(S)$ [9]为

$$R(S)=\frac{1}{N_S^{\,2}}\sum_{t_i,t_j\in S}|\rho_{t_it_j}| \tag{13}$$

综合以上两个指标得到最大相关最小冗余准则，相应的公式[9]如下：

$$I_{\mathrm{mRMR}}=\max_S[D(S,d)-R(S)] \tag{14}$$

式中 I_{mRMR} 为最大相关最小冗余指标。

求解满足最大相关最小冗余准则的特征集 S 即为最优特征集。

2.3 mRMR 的求取

最优特征集 S 的求解可转化为优化问题,可分为增量搜索法[10-12]与群体智能算法[27]两类。但是，增量搜索法可能存在首个特征选取不当的问题，群体智能算法则易陷入局部最优。考虑到用户用电行为的初始特征数量不大(本文为 10)，因此本文采用遍历法，可得到全局最优解。

令 f_i 为的集合隶属度指示函数，对其进行 0-1 编码，$f_i=1$ 表示该特征存在于 S 中，则表示在 S 中不存在标签 t_i。为简化公式表达，将互信息与相关系数分别用 a_i 与 b_{ij} 表示，即：

$$\begin{cases}a_i=I(t_i;d)\\ b_{ij}=\rho_{t_it_j}\end{cases} \tag{15}$$

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

将式(11)(13)(15)代入式(14)后得到：

$$I_{\mathrm{mRMR}}=\max_{f\in\{0,1\}^n}\left[\frac{\sum_{i=1}^{n}a_i f_i}{\sum_{i=1}^{n}f_i}-\frac{\sum_{i,j=1}^{n}b_{ij}f_i f_j}{(\sum_{i=1}^{n}f_i)^2}\right] \tag{16}$$

遍历 $f=(0,0\cdots,$ 至 $f=(1,1,\cdots,1)$ 得到使 I_{mRM} 最大的 f 向量，解码后得到最优特征集 S。

3　基于最优特征集的用户用电行为画像

3.1　特征量化

用户用电行为标签由两部分组成：类别标签与行为标签。类别标签由聚类分析结果得到，行为标签即为第 2 节得到的优质特征。用户用电行为数据大多为数值型数据，需要经过一定的转化规则才能转化为便于业务人员理解的标签。

本文采用打分制，满分 10 分，以每类用户每个标签的得分来衡量该类用户的用电特性。每类用户每个标签的得分由下式得到：

$$G_{i,j}=\frac{10(\overline{t_{i,j}}-t_{j\min})}{t_{j\max}-t_{j\min}} \tag{17}$$

式中：$G_{i,j}$ 为第 i 类用户的第 j 个标签得分；$\overline{t_{i,j}}$ 为隶属于第 i 类所有用户的第 j 个标签的平均值；$t_{j\max}$、$t_{j\min}$ 分别为第 j 个标签的最大、最小值。

3.2　画像可视化

为使业务人员更直观掌握各类用户用电特性，对于得到的用户用电标签进行可视化展示，形成不同类型用户的用电行为画像。可视化展示分为两个部分：类内用户行为画像与类间用电特性对比。类内用户行为画像是通过例如雷达图等展示各类用户用电特性，类间用电特性对比以柱状图为表现形式，凸显各类用户的同一标签量的对比。两者结合，便于业务人员更准确便捷地了解电力用户用电行为的共性与个性。

4　用户用电行为画像流程

本文基于最优特征集的用户用电行为画像包括改进 k-means 聚类分析、最优特征集提取和画像可视化 3 个环节，实现流程如图 1 所示。

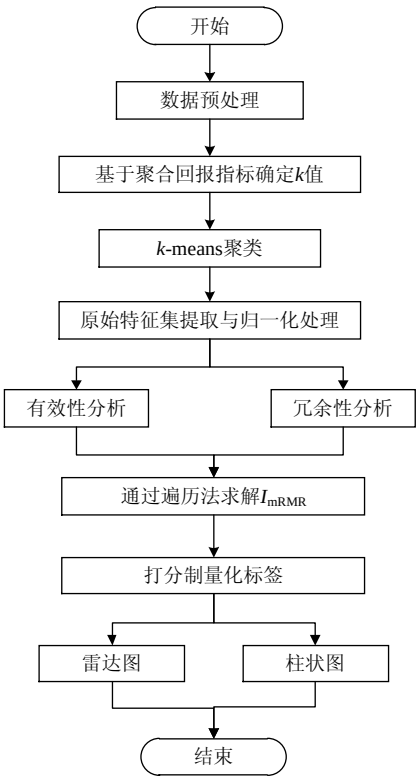


图 1　用户用电行为画像流程

Fig. 1　Flow chart of user electricity consumption behavior portrait

5　算例分析

本文实验数据集 1 来自于 ISSDA 网站发布的爱尔兰智能电表实际量测数据[28]，实验数据集 2 来自 UCI 网站发布数据[29]。数据 1 采集了爱尔兰 6277 个居民用户于 2009 年 7 月 14 日的日用电数据，每 30 min 采集一次，每个用户每天 48 个采样点，共计 6277 组数据。数据集 2 为 178 个的有标签数据，在其上叠加了 5%噪声数据，用以对比分析本文提出的 k 值确定指标的有效性。本文采用数据集 1、2 分析 k 值确定指标的有效性；采用数据集 1 分析本文基于最优特征集的用户用电行为画像方法的有效性。本文使用 MATLAB 进行仿真，以验证算法的合理性和有效性。

5.1　k 值确定指标对比分析

基于数据集 1、2 分别采用典型聚类有效性指标 SSE[22]、DBI[21]、CHI[21]和聚合回报指标分析 k 值的确定。DBI、CHI 分别取最小值和最大值时 k 为最佳。结果分别如图 2、3 所示。

数据集 1 具有样本密度差异大、子集接近的特点。图 2 中可以看到 SSE 值在 k 为 3 处趋于平缓，CHI 在 k 为 3 时取值最大，本文指标聚合回报值同样在 k 为 3 时取值最大，DBI 在 k 为 2 时取值最小。由于样本具有子集邻近的特点，而 DBI 采用聚类中心之间的最小成对距离作为分离度的评估，对于具有子群集的数据集，当彼此靠近的子群集被视为一个大群集时，分离度将达到最大值，因而，容易将接壤的两个小子集看作一个大群集。

图 3 数据集为含噪声的有标签数据，其最佳分类结果为 3 类。SSE 的拐点、DBI 最小值、本文指标聚合回报最大值皆为 3，而 CHI 在 k 为 2 时取最

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

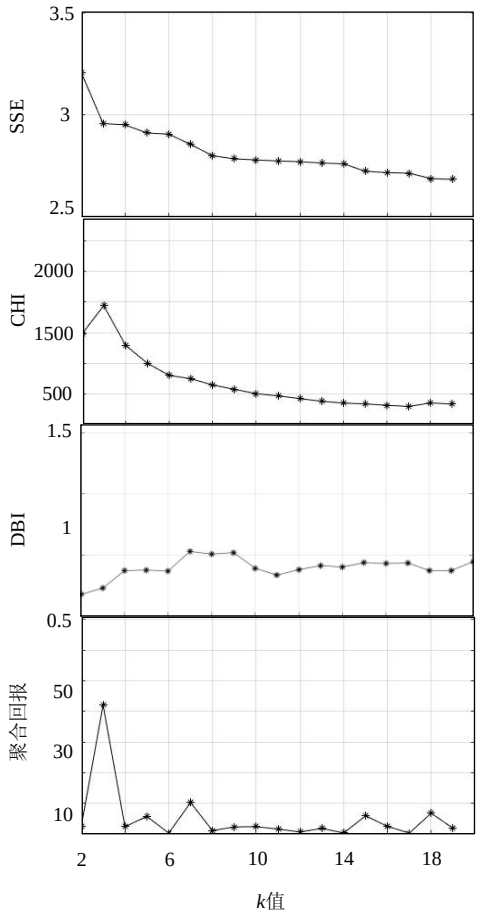


图 2 基于数据集 1 的最佳 *k* 值选取过程

Fig. 2 Optimal *k* selection process based on dataset 1

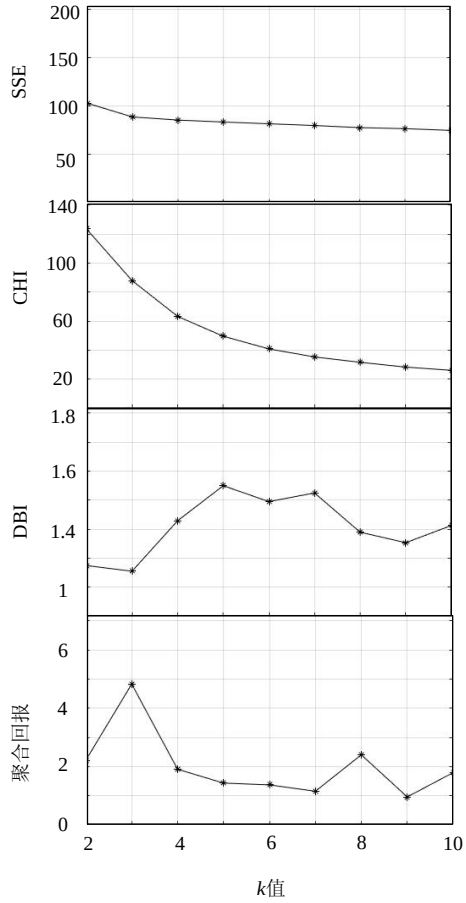


图 3 基于数据集 2 的最佳 *k* 值选取过程

Fig. 3 Optimal *k* selection process based on dataset 2

大值。CHI 以聚类中心与整体均值的距离和作为类间的分散性评估，整体均值为数据集常数，极易受噪声影响，故该指标在存在大量噪声时效果不好。

综合分析可知，本文所提聚合回报指标可以在含噪声、存在子集的数据集中表现优秀，并且相对 SSE 而言更为直观。

5.2 算例聚类分析

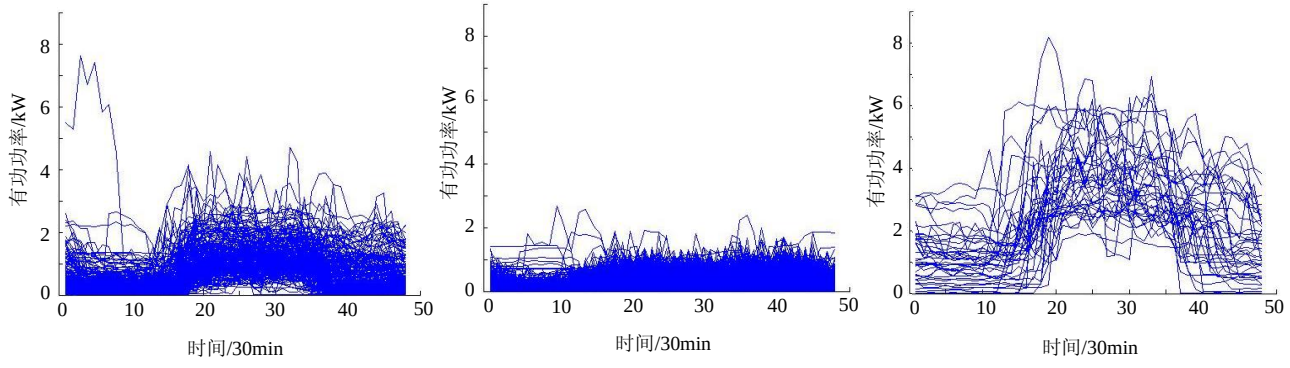
接下来，以数据集 1 为基础，构建基于最优特征集的用户用电行为画像。

首先，对负荷数据进行预处理，预处理主要包括缺失数据与失真数据的填补与剔除。然后对预处理后的负荷数据进行聚类分析。

如图 2，*k* 值在取到 3 时聚合回报最大，因此最佳 *k* 值为 3。

然后进行聚类分析，得到 3 类用户，如图 4 所示。3 类用户的聚类中心如图 5 所示。

图 4 中 A 类用户与 C 类用户峰谷段相似，但 C 类用户峰谷差较大，次峰时段从下午一直延伸至晚上，日最大负荷在 13:00—15:00，A 类用户次峰时段在夜晚，日最大负荷在 18:00—20:00。B 类用户



(a) A 类用户用电曲线 (b) B 类用户用电曲线 (c) C 类用户用电曲线

图 4 聚合后 3 类用户用电曲线

Fig. 4 Three types of user electricity consumption curves after clustering

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

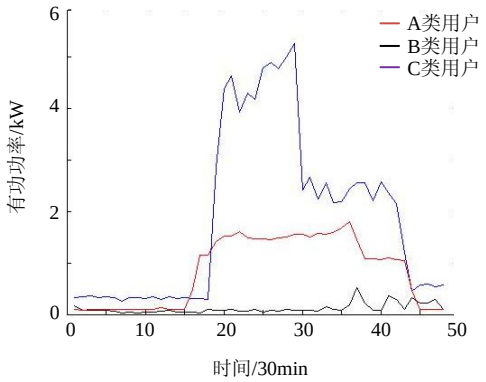


图 5　聚类中心

Fig. 5　Center of clustering

整体负荷量较低，3 次小高峰都处于晚上。因此，3 类用户的类别标签可分别归纳为午晚长峰型用户、晚间单峰型用户、午高峰晚次峰型用户。

5.3　特征选择分析

构建原始特征集 T={日用电量，日最大负荷、日最小负荷、日平均负荷，日峰谷差，谷电系数，日负荷率、日峰谷差率，峰时耗电率，平时段用电百分比}，并将特征依次以编号 1, 2, 3…表示。受制于数据的获取，本文样本仅包含用户用电数据，故本文只涉及反映用户用电特性的标签提取，不包含用户基本属性标签与非用电行为类标签。

以信息熵为衡量指标，结合聚类结果可以得到所有特征的互信息值，反映了不同特征的有效性。如图 6 所示。

以相关系数为衡量指标，得到各特征量之间的关联系，反映了特征之间囊括的信息的重复性，其值介于–1 至 1 间，绝对值越大信息重复度越高。如表 1 所示。

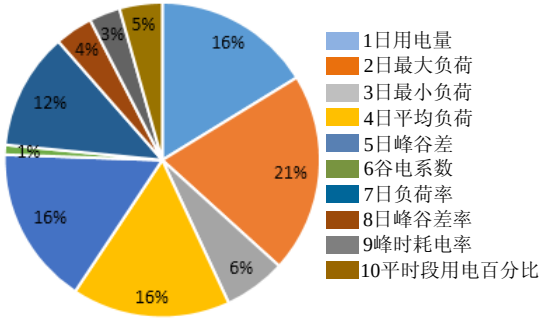


图 6　全体特征的互信息

Fig. 6　Mutual information of all features

表 1　特征间相关系数

Tab. 1　Correlation between features

特征编号	1	2	3	4	5	6	7	8	9	10
1	1	0.861	0.886	1	0.768	–0.104	0.276	–0.140	–0.064	0.151
2	0.861	1	0.641	0.861	0.983	–0.247	–0.035	0.101	0.040	0.176
3	0. 886	0.641	1	0.886	0.491	0.028	0.322	–0.281	–0.081	0.052
4	1	0.861	0.886	1	0.768	–0.104	0.276	–0.140	–0.064	0.151
5	0.768	0.983	0.491	0.768	1	–0.287	–0.115	0.181	0.065	0.187
6	–0.104	–0.247	0.028	–0.104	–0.287	1	0.289	–0.343	–0.383	–0.496
7	0.276	–0.035	0.322	0.276	–0.115	0.289	1	–0.848	–0.282	0.020
8	–0.140	0.101	–0.281	–0.140	0.181	–0.343	–0.848	1	0.233	0.084
9	–0.064	0.040	–0.081	–0.064	0.065	–0.383	–0.282	0.233	1	–0.607
10	0.151	0.176	0.052	0.151	0.187	–0.496	0.020	0.084	–0.607	1

由图 6 可知“日最大负荷”所占比例最大，“谷电系数”所占比例最小。由此可知“日最大负荷”所能反映用户类别信息量最大，“谷电系数”所能反映用户类别信息量最小。“日用电量”、“日平均负荷”、“日峰谷差”所占比例仅次于“日最大负荷”，如若仅考虑特征有效性选取最优特征，则应选取“日最大负荷”、“日用电量”、“日平均负荷”等特征。而由表 1 特征间相关性可知，“日用电量”与“日平均负荷”两特征相关系数为 1，即两者间线性相关，同时选取会存在信息量冗余的情况。由此可见，最优特征集的选取需综合考量特征自身有效性与特征间信息量的冗余性。

基于 mRMR 准则综合分析特征有效性以及特征间信息冗余性，采用遍历法求解得到使 mRMR 值最大的隶属度函数值 f 为[0, 0, 0, 1, 0, 0, 1, 0, 0, 1]。解码得到所选特征编号为 4、7、10，对应特征为“日平均负荷”、“日负荷率”与“平时段用电百分比”。

为验证所选取的最优特征集的有效性与精简性，以负荷曲线分类结果为标准，以计算时间、分类准确率、迭代次数为衡量指标，对比本文方法形成的特征集与“原始特征集”、“文献[8]特征集”和“互信息最大 3 个特征组成的特征集”，结果如表 2 所示。为准确体现不同特征集的分类性能，不受分类方法本身干扰，均采用 k-means 聚类算法进行分类，k 值取 3。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

表 2 不同特征集分类性能对比

Tab. 2 Comparison of classification performance of different feature sets

特征集	特征	准确率/%	计算时间/s	迭代次数
原始特征集	1—10	88.19	22.29	19
文献[8]特征集	4,6,10	95.12	21.72	27
互信息最大 3 个特征	2,4,5	79.63	22.45	14
本文特征集	4,7,10	98.06	19.36	12
负荷曲线	48 个时间点负荷	—	28.94	27

根据表 2 对比可知，本文的特征集分类效果无论在准确性还是速度上都优于其他对比方法。原始特征集包含全部特征，较本文特征集所增加的特征带来的信息有效性减少，冗余性增加，冗余信息的增加对分类结果带来了干扰，从而导致准确率下降。互信息最大特征集包含“日最大负荷”、“日平均负荷”和“日峰谷差”，“日平均负荷”与“日用电量”互信息值相同，但由于这两个特征线性相关，选其一即可，本文选用“日平均负荷”，该特征集准确率较低，可见仅考虑特征自身有效性是不足的。文献[8]特征集与本文特征集相似，都包含“日平均负荷”与“平时段用电百分比”两个特征，其第 3 个特征为“谷电系数”，该特征集更偏向于峰谷性的衡量，本文特征集则更关注整体用电量大小。由此可见，面对不同的样本集选取合适的特征集是很有必要的，而本文方法所优选出的特征集能更好地适应本文的样本集的分析。

5.4 用户用电行为画像

前文以用户日用电曲线为基础，经过聚类、特征提取得到最优特征集。根据式(17)可得每类用户每种标签的得分，并以雷达图为载体展示，得到每类用户用电特性画像，如图 7 所示。类间用电特性对比以柱状图为表现形式，如图 8 所示。

图 7 中的 3 类用户的标签画像可以较为直观地展现各类用户自身的用电行为特性，是个性的体现。日平均负荷反映了该用户整体用电量水平的高低；负荷率为日平均负荷与日最大负荷的比值，衡量平均负荷与最高负荷之间的差异程度，反映了该类家庭电力设备的利用率；平时段用电百分比为平段用电量与总用电量的比值，反映了用户用电波动性强弱。

图 8 作为不同类型用户同标签对比图，既将差异放大，同时也可以凸显不同类用户用电习惯的共性。两部分可视化表达相结合有助于业务人员快速准确地把握各类用户用电习惯，对于为用户制定个性化服务与评估用户群体可调控潜力而言具有重要参考价值。

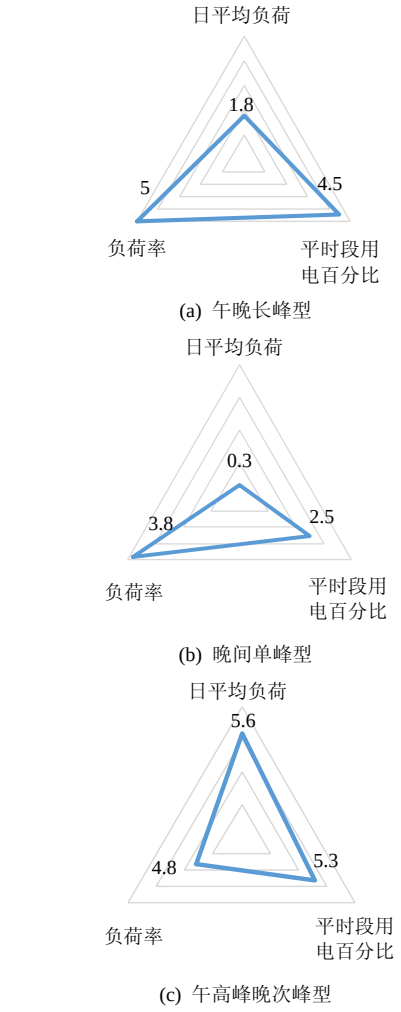


图 7 用户用电行为画像

Fig. 7 User electricity consumption behavior portrait

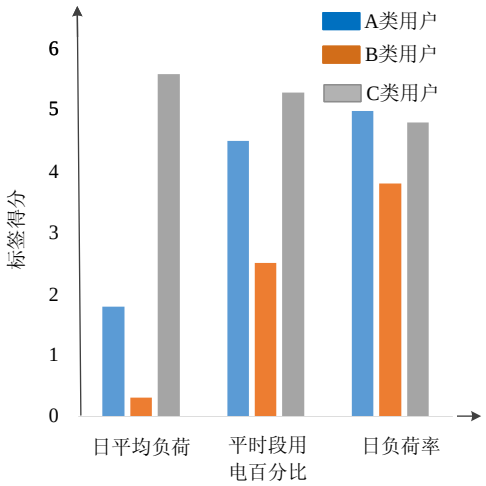


图 8 类间标签对比

Fig. 8 Comparison of labels

6 结论

本文提出了一种电力用户用电特征选择与行为画像方法。针对 k-means 聚类算法需人为参与 k 值选取的缺点做出改进，提出了聚合回报指标作为 k 值选取依据，实现了最佳 k 值的自动确定；引入

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

了最大相关最小冗余准则进行用户用电特征选取，采用了遍历法从原始特征集找到满足与目标类别相关性最大、相互间冗余性最小的优质特征集；在此基础上，采用打分制作为特征量化方法，并通过雷达图和柱状图对用户用电特性及类间特性对比作出展示。算例分析表明了本文所提方法可以自动确定用户类别，有效选取优质特征作为画像标签，从而构建各类用户用电行为画像。

参考文献

[1] 中共中央国务院．关于进一步深化电力体制改革的若干意见(中发[2015]9 号)[Z]．2015．

[2] 李扬，王蓓蓓，李方兴．灵活互动的智能用电展望与思考[J]．电力系统自动化，2015，39(17)：2-9．
Li Yang，Wang Beibei，Li Fangxing．Outlook and thinking of flexible and interactive utilization of intelligent power[J]．Automation of Electric Power Systems，2015，39(17)：2-9(in Chinese)．

[3] 陈志明，胡震云．UGC 网站用户画像研究[J]．计算机系统应用，2017，26(1)：24-30．
Chen Zhiming，Hu Zhenyun．User portrait study on UGC website [J]．Journal of Computer Applications，2017，26(1)：24-30(in Chinese)．

[4] 费鹏，林鸿飞，杨亮，等．一种用于构建用户画像的多视角融合框架[J]．计算机科学，2018，45(1)：179-182，204．
Fei Peng，Lin Hongfei，Yang Liang，et al．Multi-view ensemble framework for constructing user profile[J]．Computer Science，2018，45(1)：179-182，204(in Chinese)．

[5] 吕辉，许道强，仲春林，等．基于电力大数据的标签画像技术与应用研究[J]．电力信息与通信技术，2017，15(2)：43-48．
Lv Hui，Xu Daoqiang，Zhong Chunlin，et al．Study on tag portrait technology based on electric power big data and its application [J]．Electric Power Information and Communication Technology，2017，15(2)：43-48(in Chinese)．

[6] 王成亮，郑海雁．基于模糊聚类的电力客户用电行为模式画像[J]．电测与仪表，2018，55(18)：77-81．
Wang Chengliang，Zheng Haiyan．A portrait of electricity consumption behavior mode of power users based on fuzzy clustering[J]．Electrical Measurement & Instrumentation，2018，55(18)：77-81(in Chinese)．

[7] 罗有志，熊华斌．基于差异化密度聚类的电力客户画像分析[J]．湖南电力，2017，37(S2)：110-112．
Luo Youzhi，Xiong Huabing．Customer portrait analysis on differential density clustering[J]．Hunan Electric Power，2017，37(S2)：110-112(in Chinese)．

[8] 陆俊，朱炎平，彭文昊，等．智能用电用户行为分析特征优选策略[J]．电力系统自动化，2017，41(5)：58-63，83．
Lu Jun，Zhu Yanping，Peng Wenhao，et al．Feature selection strategy for electricity consumption behavior analysis in smart grid [J]．Automation of Electric Power Systems，2017，41(5)：58-63，83(in Chinese)．

[9] Peng Hanchuan，Long Fuhui，Ding Chris．Feature selection based on mutual information criteria of max-dependency，max-relevance and min-redundancy[J]．IEEE Transactions on Pattern Analysis and Machine Intelligence，2005，27(8)：1226-1238．

[10] 辜超，杨祎，张晓星，等．基于最大相关最小冗余准则的变压器故障诊断特征选择[J]．电工电能新技术，2018，37(7)：84-89．
Gu Chao，Yang Yi，Zhang Xiaoxing，et al．Feature selection for transformer fault diagnosis based on maximal relevance and minimal redundancy criterion[J]．Advanced Technology of Electrical Engineering and Energy，2018，37(7)：84-89(in Chinese)．

[11] 李扬，顾雪平．基于改进最大相关最小冗余判据的暂态稳定评估特征选择[J]．中国电机工程学报，2013，33(34)：179-186，27．
Li Yang，Gu Xueping．Feature selection for transient stability assessment based on improved maximal relevance and minimal redundancy criterion[J]．Proceedings of the CSEE，2013，33(34)：179-186，27(in Chinese)．

[12] 赵永宁，叶林．区域风电场短期风电功率预测的最大相关-最小冗余数值天气预报特征选取策略[J]．中国电机工程学报，2015，35(23)：5985-5994．
Zhao Yongning，Ye Lin．A numerical weather prediction feature selection approach based on minimal-redundancy-maximal-relevance strategy for short-term regional wind power prediction[J]．Proceedings of the CSEE，2015，35(23)：5985-5994(in Chinese)．

[13] 潘超，秦本双，何瑶，等．基于优化 FCM 聚类的 RELM 风速预测[J]．电网技术，2018，42(3)：842-848．
Pan Chao，Qin Benshuang，HE Yao，et al．Wind speed forecasting of regularized ELM based on optimized FCM clustering[J]．Power System Technology，2018，42(3)：842-848(in Chinese)．

[14] 赵莉，候兴哲，胡君，等．基于改进 k-means 算法的海量智能用电数据分析[J]．电网技术，2014，38(10)：2715-2720．
Zhao Li，Hou Xingzhe，Hu Jun，et al．Improved k-means algorithm based analysis on massive data of intelligent power utilization [J]．Power System Technology，2014，38(10)：2715-2720(in Chinese)．

[15] 廖伟涵，郭创新，金宇，等．基于四阶段预处理与 GBDT 的油浸式变压器故障诊断方法[J]．电网技术，2019，43(6)：2195-2203．
Liao Weihan，Guo Chuangxin，Jin Yu，et al．Oil-immersed transformer fault diagnosis method based on four-stage preprocessing and GBDT[J]．Power System Technology，2019，43(6)：2195-2203(in Chinese)．

[16] 王保义，胡恒，张少敏．差分隐私保护下面向海量用户的用电数据聚类分析[J]．电力系统自动化，2018，42(2)：121-127．
Wang Baoyi，Hu Heng，Zhang Shaomin．Differential privacy protection based clustering analysis of electricity consumption data for massive consumers[J]．Automation of Electric Power Systems，2018，42(2)：121-127(in Chinese)．

[17] 彭春华，余愿，孙惠娟．基于源网荷协同优化的配电网光储联合系统规划[J]．电网技术，2019，43(11)：3944-3951．
Peng Chunhua，Yu Yuan，Sun Huijuan．Planning of combined PV-ESS system for distribution network based on source-network-load collaborative optimization[J]．Power System Technology，2019，43(11)：3944-3951(in Chinese)．

[18] 宋易阳，李存斌，祁之强．基于云模型和模糊聚类的电力负荷模式提取方法[J]．电网技术，2014，38(12)：3378-3383．
Song Yiyang，Li Cunbin，Qi Zhiqiang．Extraction of power load patterns based on cloud model and fuzzy clustering[J]．Power System Technology，2014，38(12)：3378-3383(in Chinese)．

[19] 陈烨，吴浩，史俊祎，等．奇异值分解方法在日负荷曲线降维聚类分析中的应用[J]．电力系统自动化，2018，42(3)：105-111．
Chen Ye，Wu Hao，Shi Junyi，et al．Application of singular value decomposition algorithm to dimension-reduced clustering analysis of daily load profiles[J]．Automation of Electric Power Systems，2018，42(3)：105-111(in Chinese)．

[20] 何哲楠，吴浩，程祥，等．基于变电站-用户双层结构的变电站负荷聚类研究[J]．电网技术，2019，43(8)：2983-2991．
He Zhenan，Wu Hao，Cheng Xiang，et al．Substation load clustering based on substation-consumer two-level structure[J]．Power System Technology，2019，43(8)：2983-2991(in Chinese)．

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

[21] 周开乐，杨善林，丁帅，等．聚类有效性研究综述[J]．系统工程理论与实践，2014，34(9)：2417-2431．
Zhou Kaile，Yang Shanlin，Ding Shuai，et al．On cluster validation [J]. Systems Engineering-Theory & Practice，2014，34(9)：2417-2431 (in Chinese)．

[22] 张斌，庄池杰，胡军，等．结合降维技术的电力负荷曲线集成聚类算法[J]．中国电机工程学报，2015，35(15)：3741-3749．
Zhang Bin，Zhuang Chijie，Hu Jun，et al．Ensemble clustering algorithm combined with dimension reduction techniques for power load profiles[J]．Proceedings of the CSEE，2015，35(15)：3741-3749(in Chinese)．

[23] 宋军英，何聪，李欣然，等．基于特征指标降维及熵权法的日负荷曲线聚类方法[J]．电力系统自动化，2019，43(20)：65-76．
Song Junying，He Cong，Li Xinran，et al．Daily load curve clustering method based on feature index dimension reduction and entropy weight method[J]．Automation of Electric Power Systems，2019，43(20)：65-76(in Chinese)．

[24] 张素香，刘建明，赵丙镇，等．基于云计算的居民用电行为分析模型研究[J]．电网技术，2013，37(6)：1542-1546．
Zhang Suxiang，Liu Jianming，Zhao Bingzhen，et al．Cloud computing-based analysis on residential electricity consumption behavior[J]．Power System Technology，2013，37(6)：1542-1546(in Chinese)．

[25] 张承畅，张华誉，罗建昌，等．基于云计算和改进 K-means 算法的海量用电数据分析方法[J]．计算机应用，2018，38(1)：159-164．
Zhang Chengchang，Zhang Huayu，Luo Jianchang，et al．Massive data analysis of power utilization based on improved K-means algorithm and cloud computing[J]．Journal of Computer Applications，2018，38(1)：159-164(in Chinese)．

[26] 原媛，顾洁，黄薇，等．互信息在电力系统中长期负荷预测中的应用[J]．华东电力，2009，37(2)：236-239．
Yuan Yuan，Gu Jie，Huang Wei，et al．Application of mutual information to power system medium and long-term load forecasting [J]．East China Electric Power，2009，37(2)：236-239(in Chinese)．

[27] 姚旭，王晓丹，张玉玺，等．基于粒子群优化算法的最大相关最小冗余混合式特征选择方法[J]．控制与决策，2013，28(3)：413- 417，423．
Yao Xu，Wang Xiaodan，Zhang Yuxi，et al．A maximum relevance minimum redundancy hybrid feature selection algorithm based on particle swarm optimization[J]．Control and Decision，2013，28(3)：413-417，423(in Chinese)．

[28] Commission for Energy Regulation．CER smart metering project-electricity customer behavior trial，1st edition[DB/OL]．[2020-05-05]．https://www.ucd.ie/issda/data/commissionforenergyregulationcer/．

[29] Forina M，et al．Wine data set[DB/OL]．(1991-07-01)[2020-05-11]．http://archive.ics.uci.edu/ml/datasets/Wine．



赵晋泉

收稿日期：2019-10-21。

作者简介：

赵晋泉(1972)，男，教授，博士生导师，通信作者，主要研究方向为电力系统优化运行、电压稳定分析与控制、电力市场和大电网智能调度，E-mail：zhaojinquan@hhu.edu.cn；

夏雪(1995)，女，博士研究生，主要研究方向为用户用电分析，E-mail：xx382880230@163.com；

刘子文(1991)，男，博士，讲师，主要研究方向为柔性直流输电系统运行特性分析与控制，E-mail：liuziwen@hhu.edu.cn。

（责任编辑　王金芝）

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net